Proyecto Final CFGS Desarrollo de Aplicaciones Multiplataforma

Carlos Manso

2023 - 2024

Contents

1 Introducción

1.1 Origen

La elección de este proyecto surge después de una intensa búsqueda de ideas entre las que se encuentran proyectos como una aplicación de estudios, un videojuego, un motor gráfico, una aplicación de memorización... Proyectos que me atraían para desarrollar, pero que no veía con tanto uso en el futuro como la opción finalmente elegida.

El proyecto consiste, en su forma más conceptual, en una inteligencia artificial capaz de predecir un *kanji*[1] a través de su imagen, ya sea caligrafiado o impreso, y devolver dicho kanji en texto copiable para poder usarlo, buscarlo, o reconocerlo con mayor facilidad.

El resultado que les muestro en la memoria a continuación no ha sufrido grandes modificaciones en el desarrollo y las metas que se pretendían seguir con el mismo, manteniéndose bastante fiel a la idea original, aunque sí que se han tenido que adaptar ciertos aspectos que se comentarán más adelante en esta memoria.

1.2 Motivación

Personalmente disfruto del ámbito del *data science*[1], los idiomas y desarrollar mis propias herramientas en la medida de lo posible, por lo que desarrollar una utilidad como la descrita era un paso lógico a tomar en algún momento. Como estudiante de japonés, conozco de primera mano el valor que una herramienta así puede suponer para los estudiantes de este idioma.

Además, es un proyecto muy extensible, tanto a través de nuevas funcionalidades no contempladas en el desarrollo inicial, como extendiendo su funcionamiento a otros idiomas de alfabeto no romano.

1.3 Comentario del autor

Este documento está pensado para que cualquier persona pueda entender el desarrollo en términos generales, por lo que los tecnicismos o anglicismos que se utilizan están definidos en uno de los anexos. No obstante, cabe mencionar que se da por sentado un conocimiento mínimo de informática en el lector para poder entender al completo todas las explicaciones que se desarrollan a continuación, ya que abarca tanto el objetivo del proyecto y sus motivaciones y planificaciones, como su puesta en marcha, funcionamiento y guías para desarrolladores y usuarios. Asimismo, el objetivo de este documento tampoco abarca las explicaciones sobre diversos conceptos a bajo nivel, funciones matemáticas, y otros conceptos avanzados necesarios para el desarrollo del proyecto que se presenta, que ya se encuentran desarrollados en las herramientas utilizadas. Para más información al respecto, se facilitan algunas fuentes para su consulta en los anexos correspondientes.

[1] Definiciones en Anexo 1: Términos técnicos

2 Contextualización

2.1 Necesidad

En los ámbitos personal y social, una herramienta capaz de transformar la imagen de un kanji complejo en un carácter *Unicode*[2] legible por cualquier persona y copiable en un dispositivo, es de gran utilidad para el estudio del idioma. Algunos estilos de escritura o ciertos documentos antiguos no guardan casi ningún parecido con la forma de escribir los kanji a día de hoy, especialmente a la hora de comparar caligrafía humana con caracteres digitales.

Uno de los problemas más comunes para los estudiantes de este idioma es reconocer kanjis, ya que se trata de un alfabeto de más de 3000 caracteres distintos, cada uno con varias lecturas, y que pueden combinarse para formar significados y lecturas nuevas.

Aunque las combinaciones son mucho más complejas de cotejar y requieren de un estudio y una comprensión extensa de los caracteres individuales, una aplicación que nos facilite la tarea de reconocerlos de forma aislada supone una gran herramienta, ya que en numerosas ocasiones, poder reconocerlos por separado es suficiente para contextualizar la combinación y conocer el significado de ésta.

Es en este punto donde entra en juego mi proyecto, ofreciendo una forma sencilla de reconocer caracteres kanji que el usuario pueda ver en cualquier tipo de multimedia o en formato físico. A través de una captura de pantalla o una fotografía del caracter, podrá obtenerlo en un formato digital mucho más comprensivo y versátil para su identificación o para buscar información al respecto.

2.2 Objetivo

El proyecto está, lógicamente, limitado en cierta forma tanto por el tiempo disponible para su desarrollo como por la capacidad de computación a la que tengo acceso en la actualidad para el entrenamiento del *modelo*[2].

No obstante, aunque existen Inteligencias Artificiales (de ahora en adelante *IAs*[2]) a día de hoy muy perfeccionadas como puede ser la de Google, parte del objetivo del proyecto es el de crear la propia herramienta desde cero, introduciéndome en un nuevo ámbito de la programación.

La mayoría de recursos con una funcionalidad similar a la que yo presento, no disponen de una aplicación particular para ello, no son fácilmente escalables, o requieren que el propio usuario intente plasmar el caracter a mano para su reconocimiento. Esto último supone un problema, ya que por una parte, ciertos kanjis son demasiado complejos para ser copiados a mano por el usuario; y por otra, estos métodos de reconocimiento tienen en cuenta el orden de los trazos, esto quiere decir, que por como son las reglas caligráficas del kanji, intentar plasmar el mismo caracter variando el orden de los trazos puede dar diferentes resultados.

El objetivo general es, por tanto, generar una IA y una aplicación a través de las cuales se pueda introducir la imagen de un kanji aislado, y nos devuelva el kanji de la imagen en un caracter Unicode copiable.

[2]Definiciones en Anexo 1: Términos técnicos

3 Objetivos específicos

Los objetivos específicos del proyecto se desgranan en los siguientes puntos:

- Desarrollar un modelo de IA capaz de reconocer caracteres para entender el funcionamiento elemental de un algoritmo de reconocimiento de caracteres.
- Desarrollar un modelo capaz de entrenar y reconocer caracteres japoneses, tanto escritos a mano como digitales con un porcentaje de acierto suficiente como para ser de utilidad.
- Crear una *Application Programming Interface* (*API*[3]) capaz de recibir imágenes de kanjis y devolver sus predicciones.
- Alojar la API en un servidor privado y exponerla a internet para poder consumir el servicio desde diferentes dispositivos en cualquier lugar donde dispongamos de acceso a internet.
- Desarrollar una interfaz gráfica de usuario con la que podamos tomar o cargar imágenes y enviarlas a un *web service*[3] que crearemos para que nos devuelva una predicción a dicha interfaz.

Las tareas a desarrollar se describen en mayor detalle en la siguiente sección, así como los detalles sobre los procesos utilizados, resultados, código fuente, etc. También se podrá encontrar documentación adicional a todos estos procesos en los anexos correspondientes.

4 Tareas

Respecto a las tareas a realizar a nivel de proyecto para poder llevar a cabo los objetivos mencionados en el punto anterior, se plantean cuatro puntos bien diferenciados, que se desgranan a su vez en diferentes subtareas. La lista de tareas viene especificada a continuación, y desarrollada en la sección 5, donde se explica cada una de forma detallada.

- Modelo de prueba
- Entrenamiento del modelo
  - Elección de librerías
  - Búsqueda del *dataset*[3]
  - Diseño de la *red neuronal*[3]
  - Diseño del entrenamiento
  - Validación
- Implementación
  - Configuración de los métodos
  - Presentación del resultado
- Alojamiento
  - Montaje e instalación del servidor
  - Networking
  - Dockerización
- Creación de la interfaz
  - Frontend
  - Backend

[3]Definiciones en Anexo 1: Términos técnicos

5 Desarrollo

5.1 Modelo de prueba

La idea es realizar un modelo básico de IA capaz de clasificar correctamente imágenes de números para familiarizarme con el lenguaje y con los tipos y formatos de datos con los que se tendrá que trabajar durante el desarrollo.

Cabe mencionar que esta parte del proyecto tiene una fase previa de investigar y documentarse acerca de qué lenguaje utilizaremos para esto. En el momento del desarrollo, la herramienta más utilizada para creación de IAs es Python 3, por lo que de este punto inclusive en adelante, será el lenguaje que usaremos para nuestro desarrollo, salvo que se indicase lo contrario de forma específica.

Para realizar este punto, se busca una guía paso a paso sobre cómo desarrollar una IA muy básica llamada *Clasificador KNN*[4] de reconocimiento de dígitos, sin embargo, como no es el objetivo original de este proyecto, no vamos a desarrollar en detalle el proceso de creación. En las pruebas realizadas se registró un ratio de acierto del 100%, con 12 imágenes tanto pertenecientes al dataset como dibujadas por el usuario. En el parámetro de certeza (encargado de medir el nivel de confianza en la predicción proporcionada) se obtienen resultados en torno al 80%. Se incluye el código de este algoritmo en el *anexo 3*, pero como ya hemos comentado, no entraremos en más detalle al respecto, puesto que no tiene estricta relación con el propósito del proyecto.

Ejemplo de input para entrenamientos y validaciones del KNN

5.2 Entrenamiento del modelo

Una vez finalizada la prueba de concepto, se comienza con el desarrollo del modelo, esto es, su proceso de creación, entrenamiento, validación, uso, etc. Para ello debemos subdividir esta sección en varias partes que, no obstante, están interrelacionadas, y por tanto pueden verse afectadas entre sí. A continuación se explican cada una de estas subtareas:

5.2.1 Elección de librerías

Existen ciertas librerías básicas de las que debemos partir. Para ello debemos realizar un estudio sobre las tecnologías y procesos que necesitaremos, qué funcionalidades vamos a desarrollar y de qué herramientas necesitaremos disponer. No obstante, a lo largo del desarrollo podremos ir necesitando librerías adicionales con las que no hayamos contado en primer lugar que habrá que tener en cuenta a la hora de documentar el proyecto.

En nuestro caso, se contempla inicialmente la posibilidad de utilizar PyTorch, una librería de IA bastante conocida y con amplia trayectoria, pero tras navegar a través de la documentación e informarse a través de diversas fuentes, se decide finalmente utilizar la librería de Tensorflow, debido a, entre otros

[4]Definiciones en Anexo 1: Términos técnicos

motivos, una mayor facilidad de uso de su API, una documentación más extensa y explicativa, y mayor uso entre los desarrolladores actuales de IAs, lo que se traduce en mayor contenido e información respecto a los diversos problemas y opciones con las que nos enfrentamos durante el desarrollo.

Adicionalmente a la librería de Tensorflow, conocemos ciertas librerías que necesitaremos usar con seguridad a lo largo del desarrollo como PIL(Pillow) para manejo de imágenes, Matplotlib para generación de gráficos informativos, Keras como anexo a Tensorflow para el entrenamiento, Numpy para creación de matrices y otras colecciones con el poder computacional que ofrece C, y muy importante, Torch-directml para integrar entrenamientos de IA con gráficas de AMD a través de Direct-X12.

5.2.2 Búsqueda del dataset

Parte esencial de la creación de una IA, es utilizar un dataset adecuado, por lo que, a falta de capacidad y tiempo para generar uno propio, debemos buscar un dataset ya existente con los contenidos que necesitemos y, de si no cumpliese nuestras expectativas, adaptarlo a nuestras necesidades.

La elección del dataset se ve condicionada por la escasez de éstos. Esencialmente, podemos encontrar dos datasets distintos en internet.

El primero es ELTCDB, que aunque a primera vista tiene una mejor calidad de datos, éstos vienen en un formato más incómodo para trabajar con él. Esencialmente, debes pedir permiso al AIST (National Institute of Advanced Industrial Science and Technology) para obtener acceso, y una vez concedido, todos los datos se encuentran en binario, subdivididos de forma irregular y bajo un estándar propio del AIST, quien te proporciona las instrucciones para decodificarlos correctamente.

Es por la complejidad en el proceso de obtener los datos en el formato que queremos, que se opta por la segunda opción: Kuzishiji-Kanji, que sí que viene en un formato conveniente para nuestro caso de uso. Como inconveniente de este dataset, cabe destacar que sus datos están ligeramente más desfasados, es algo más incompleto y está peor balanceado.

Sin embargo, aunque la eficacia de la IA se verá mermada por la integridad del dataset, elegimos este dataset, ya que la implementación del modelo puede hacerse casi de forma directa a través de la API de Keras.

Para compensar este desbalance del dataset, se crean tres scripts:

- El primero genera, en base a diferentes fuentes en japonés, una imagen acorde al formato de las imágenes contenidas en nuestro dataset por cada kanji disponible para aumentar el número de muestras.
- El segundo se encarga de recorrer de nuevo el dataset, eliminando todas las carpetas e imágenes que contengan menos de diez muestras, el mínimo que consideramos para obtener un resultado consistente. Esto se hace teniendo en cuenta que el anterior script generará aproximadamente, 7 muestras por kanji.
- El tercero se encarga de normalizar el número de muestras. Lo ideal es que se entrene bajo un rango sin una gran discrepancia entre mayor y menor número de muestras. Para esto, en nuestro script se generan por data augmentation nuevas muestras en aquellos kanji por debajo de un umbral mínimo, y se eliminan muestras aleatorias en aquellos por encima de un umbral máximo. En nuestro caso, los umbrales se sitúan en 500 muestras máximo, y 80 mínimo.

Cabe destacar que los kanji en los que ocurre esto son, generalmente, muy poco comunes de ver, o que han caído en desuso.

5.2.3 Diseño de la red neuronal

Es importante realizar un estudio en profundidad de los diseños de redes neuronales recomendables para la funcionalidad que estamos buscando, y, posteriormente, analizar los resultados de la *validación*[5] y

[5]Definiciones en Anexo 1: Términos técnicos

realizar pruebas de los modelos generados utilizando esta red para poder ajustar sus parámetros de configuración acorde con el dataset que le vamos a proporcionar.

Antes de comenzar con explicaciones más técnicas, conviene conocer la siguiente terminología:

- Capa: Una capa es el bloque más general dentro de un modelo de IA. Son contenedores que se encargan de recibir un dato de entrada, transformarlo a partir de determinadas operaciones matemáticas, y generar un dato de salida con el que informar a la siguiente (o generar un resultado final en el modelo). Las capas se dividen en *input* y *output layers*, siendo respectivamente la primera y la última capa del modelo, y *hidden layers* siendo estas todas las que se encuentren entre las dos anteriores.

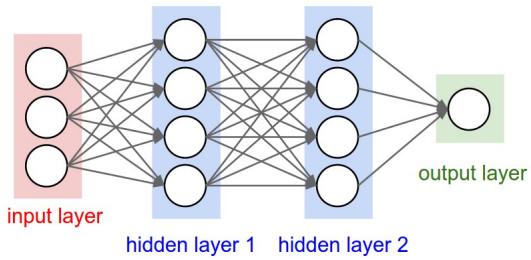

Estructura de capas en una red neuronal.

- Convolución: Se trata de una operación matemática que describe cómo fusionar dos partes de información, primero un dato de entrada (en nuestro caso concreto, el valor de cada píxel), y segundo el valor conjunto de todos los vecinos definidos por el kernel, para generar un mapa de características del dato inicial.
- Kernel: consiste en una pequeña matriz que itera sobre los datos de entrada, realizando determinadas operaciones entre el elemento seleccionado y los elementos de su alrededor y calculando un nuevo resultado para el elemento original.

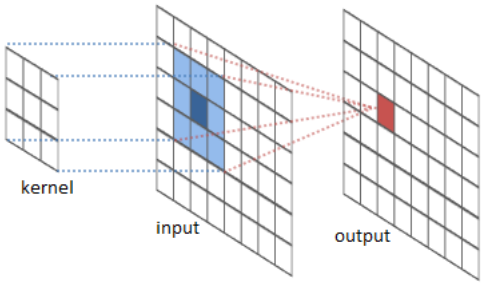

Proceso de convolución de una imagen

- Neurona: Al nivel más conceptual, una neurona es una función que opera sobre los datos de entrada (x_n), aplicándole unos pesos (w_n), y dando como resultado una salida (y) que puede ser procesada por una función de activación. Generalmente, cada una de estas unidades, se encuentra conectada en ambos sentidos a varias neuronas. Estas unidades pueden seguir diferentes patrones de conexión entre ellas o ser usadas en conjunto con múltiples funciones de activación.
- Peso: Son valores numéricos que se asocian a las conexiones entre las neuronas de diferentes capas. Estos se inicializan de forma aleatoria con la primera iteración del entrenamiento, y a partir de una serie de ecuaciones, son ajustados para las siguientes iteraciones acorde a los resultados obtenidos.

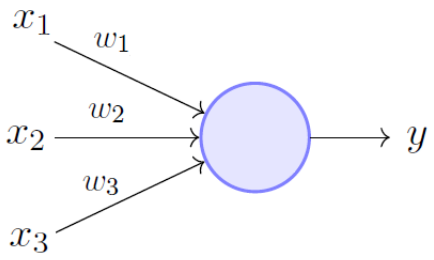

Representación del funcionamiento de una neurona

- Activación: Las funciones de activación son operaciones matemáticas que se encargan de transmitir la información generada por la neurona a las neuronas de la siguiente capa. La función de activación puede ser de muchos tipos según el resultado que se pretenda obtener. Algunos de estos tipos son Sigmoid (transformar los valores introducidos a una escala 0-1), Softmax (transformar el sumatorio de todas las salidas a 1) y que se utilizará en otros puntos relevantes del proyecto, o ReLU, como utilizamos en este caso (transformar los valores de entrada anulando los negativos y dejando los positivos sin modificar). En términos generales, se buscan funciones cuyas derivadas sean simples para minimizar al máximo el coste computacional del entrenamiento.

Vistos los términos más comunes que utilizaremos en nuestra explicación, los detalles específicos para nuestro proyecto se describen a continuación.

Se ha optado por un diseño de red convolucional (explicado más adelante) que sigue un patrón bastante extendido y recomendado para IAs cuyo objetivo es *Optical Character Recognition* (*OCR*[6]), como es nuestro caso.

En los párrafos a continuación, se procede a profundizar de forma más técnica este diseño, no obstante cabe destacar que no se ofrecen una gran cantidad de detalles con respecto a las propiedades de las herramientas que utilizamos, ya que son de una gran complejidad y se salen del objetivo de este documento.

Nuestra red neuronal está compuesta por dos bloques principales. Un primer bloque compuesto por capas de Convolución y Pooling que se encargarán de extraer información de las imágenes, y un segundo bloque compuesto por capas Densas.

Previo a las capas definidas a continuación, se aplican dos transformaciones extra, una de redimensionado, y una de reescalado, que transformarán los datos introducidos al modelo al tamaño y formato de datos requeridos por la capa inicial.

Las capas convolucionales se encargan de extraer la información relevante de la imagen a través de la iteración de un kernel por cada píxel de la imagen. Esto dará como resultado una imagen del mismo tamaño que la original donde cada píxel tendrá la información relevante sobre aquellos a su alrededor.

Las capas de MaxPooling2D, al igual que las Convolucionales, iteran un kernel por cada pixel de la imagen, pero al contrario que estas últimas, su objetivo es reducir el tamaño total de la imagen descartando los resultados menos relevantes, ayudando al modelo a centrarse en las características de mayor importancia y reduciendo el tiempo de procesamiento.

A continuación de este grupo de capas, interviene una capa de Dropout, que fuerza al modelo a ignorar cierta cantidad de neuronas que se eligen de forma aleatoria en cada iteración del entrenamiento, de forma que se incentiva a la red a buscar caminos alternativos para la resolución del problema planteado. Esto previene que el algoritmo genere una dependencia a ciertas neuronas, reduciendo el *overfitting*[6] y mejorando

[6]Definiciones en Anexo 1: Términos técnicos

la capacidad de respuesta a nuevos datos.

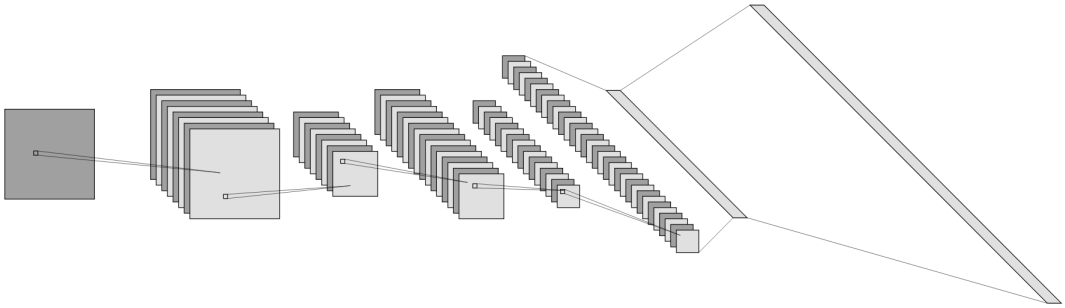

Representación LeNet de nuestro modelo

A través de una capa Flatten, simplemente transformamos los datos que hemos obtenido con las funciones anteriores en una secuencia lineal de forma que sea más simple para el algoritmo conectar los datos y entender el conjunto global de la imagen original en las siguientes capas del modelo.

Llegando al final del modelo, disponemos dos capas densas, intercaladas por otra capa Dropout. Las capas densas son aquellas donde el modelo pasa de analizar los datos a clasificarlos, para en la última capa generar un resultado final. En estas capas, cada neurona de la capa actual, está conectada a cada una de las neuronas de la capa anterior, y estas conexiones llevan asociadas un peso ajustado durante el entrenamiento. Son capas particularmente útiles en el reconocimiento de patrones. A las neuronas de estas capas también se les aplica una función de activación ReLU, que permite a la red aprender relaciones complejas entre los datos. La salida de datos tras pasar por este modelo viene directamente de la última capa densa, cuyo número de neuronas es igual al número de kanji disponibles en nuestro dataset. El valor de salida de cada una de las neuronas de la última capa, representará la probabilidad de que el kanji asociado a dicha neurona sea el mismo que el del dato de entrada.

También es importante remarcar que lo anterior es una explicación general del diseño y funcionamiento del modelo, realizado con una librería de alto nivel. El funcionamiento de esta NN y las funciones que lo componen es mucho más compleja y técnica de lo que se pretende explicar en esta documentación. Toda información al respecto puede obtenerse en la documentación oficial de Tensorflow.

```
model = Sequential([
  tf.keras.Sequential([
      layers.Resizing(64, 64),
      layers.Rescaling(1./255)
  ]),
  layers.Conv2D(16, 3, padding='same', activation='relu'),
  layers.MaxPooling2D(),
  layers.Conv2D(32, 3, padding='same', activation='relu'),
  layers.MaxPooling2D(),
  layers.Conv2D(64, 3, padding='same', activation='relu'),
  layers.MaxPooling2D(),
  layers.Dropout(0.2),
  layers.Flatten(),
  layers.Dense(128, activation='relu'),
  layers.Dropout(0.2),
  layers.Dense(len(labels), name='outputs')
])
```

5.2.4 Declaración del modelo

Terminología

- Batch: Se trata de un parámetro que se encarga de determinar el número de datos que se cargarán en memoria por cada iteración de la época actual del entrenamiento. Cuanto menor sea este número, más ruido se genera en el entrenamiento, pero mucho menor serán los recursos utilizados.
- Época: Se trata de un ciclo completo a través de todo el conjunto de datos de entrenamiento. El número de épocas indica la cantidad de iteraciones que el algoritmo de aprendizaje completará a lo largo de un proceso de entrenamiento.
- Función de pérdida: Es la función que se encarga de medir como de precisas son las predicciones que realice nuestro modelo con respecto a los resultados verídicos. El objetivo es conseguir que su resultado sea lo menor posible, es decir, que el ratio de error sea lo más pequeño posible. Aunque existen múltiples funciones de pérdida como Hinge Loss (clasificación binaria) o Mean Absolute Error (error promedio en tareas simples de regresión), en este caso se ha utilizado Categorical Cross-entropy, diseñada para tareas de clasificación multiclase, en la que se analizan las diferencias entre las probabilidades de la predicción y el valor real.
- Optimizador: Se trata de un algoritmo que se encarga de ajustar ciertos parámetros internos del modelo durante su entrenamiento, buscando minimizar el ratio de error, optimizando los pesos en base a los resultados de la función de pérdida aplicada al modelo. Existen numerosos algoritmos de optimización, y su elección dependerá de diversos factores como la velocidad de convergencia que queramos obtener, como de eficiente en términos de memoria queramos que sea, o los tipos de datos de entrada, entre otros. Algunos de los más utilizados son SGD(-Stochastic Gradient Descent-, que optimiza en base al gradiente general del modelo), RMSProp(-Root Mean Scope Propagation-, que optimiza en base al gradiente medio de los resultados más recientes), Momentum(que toma como base SGD, pero teniendo en cuenta también la media global en lugar de los resultados individuales), Adam(-Adapting Moment Estimation- que ajusta individualmente los parámetros combinando los algoritmos de RMSProp y Momentum)...
- Gradiente: Es un vector calculado en base a las derivadas parciales de nuestra función de pérdida y nuestro ratio de aprendizaje. Simplificando, es una guía que utiliza nuestro algoritmo para modificar sus pesos de forma dinámica y generar mejores resultados, es decir, si nuestro objetivo es llegar al punto 0 en una curva descendente de errores, el gradiente sería la verticalidad de la pendiente de la curva.

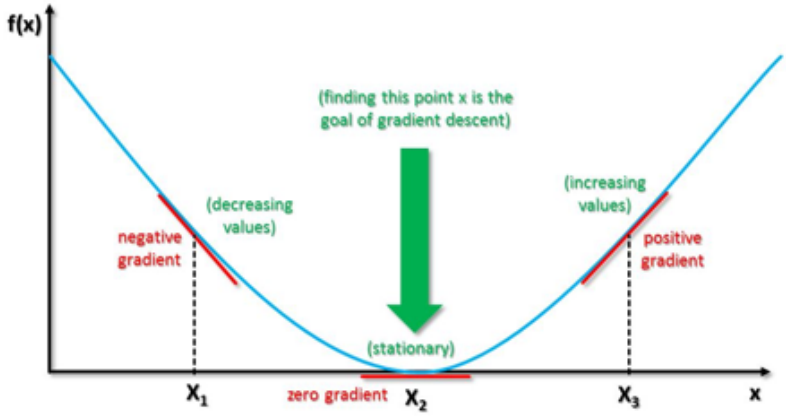

- Momentum: Aunque se ha mencionado anteriormente como un optimizador per se, es un concepto importante en el uso de optimizadores para IA, que puede usarse como parámetro en varios de ellos.

En nuestro caso, utilizando el algoritmo Adam, no es necesario, ya que es un algoritmo adaptativo, pero en muchos otros optimizadores es necesario definir esta variable, que se encarga de superar el falso mínimo con el que el optimizador va a toparse en su entrenamiento. La función de pérdida no siempre genera una derivada con una curva regular, en muchas ocasiones, la curva tendrá numerosas subidas y bajadas. Es para conseguir ignorar el mínimo local que existe este parámetro, definiendo un rango de gradiente ascendente a ignorar, que haga que el entrenamiento siga adelante a pesar de haber alcanzado un mínimo aparente.

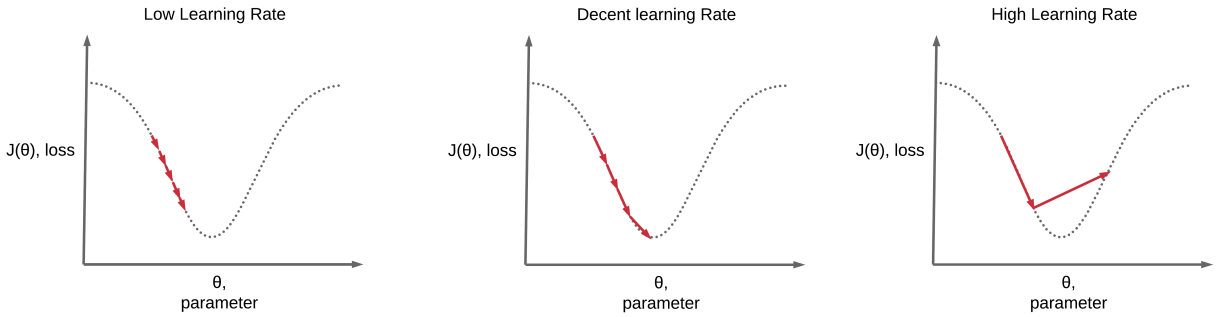

Dado el diseño de la red neuronal definido en el punto anterior, comenzamos con la declaración del modelo con vistas a su entrenamiento, guardado, validación y posterior uso.

Es importante destacar que el entrenamiento de una IA tiene una gran parte de ensayo-error, por lo que en el código que veremos a continuación, aunque los parámetros son los utilizados en el entrenamiento final del modelo, para llegar a ellos han sido necesarios muchos intentos y modificar muchas variables junto con las comprobaciones posteriores pertinentes hasta llegar a ellos.

La declaración del modelo y otros parámetros necesarios, se definen a través de la API de Tensorflow junto con Keras, que pone a nuestra disposición numerosas utilidades de las cuales podemos informarnos a través de su documentación oficial. El código se muestra a continuación:

```
dataset_dir = pathlib.Path('instalation/data/Kanji_Images')

batch_size = 32
source_height = 64
source_width = 64

training_dataset = tf.keras.utils.image_dataset_from_directory(
  dataset_dir,
  validation_split=0.2,
  subset='training',
  seed=39,
  image_size=(source_height, source_width),
  batch_size=batch_size)

validation_dataset = tf.keras.utils.image_dataset_from_directory(
  dataset_dir,
  validation_split=0.2,
  subset='validation',
  seed=39,
  image_size=(source_height, source_width),
  batch_size=batch_size)

optimizer_model = keras.optimizers.Adam(learning_rate=0.0005)
loss_model = tf.keras.losses.SparseCategoricalCrossentropy(from_logits=True)
model.compile(optimizer=optimizer_model,
            loss=loss_model,
            metrics=['accuracy'])
epochs = 50
training = model.fit(training_dataset,
                  validation_data=validation_dataset,
                  epochs=epochs)
model.save('trainings/fullmodel2.keras')
```

En primer lugar, nos encargamos de crear las variables que contendrán el directorio de nuestro dataset, el tamaño del batch, y el alto y ancho de las imágenes de nuestro dataset.

A continuación, definimos los dataset de entrenamiento y validación a través de una de las herramientas ofrecidas por Keras, a las que le pasaremos el directorio, el porcentaje de separación aleatoria entre dataset de entrenamiento y validación, el nombre del subset, una semilla de aleatoriedad para evitar que la IA se acostumbre a determinados patrones, el tamaño de nuestras imágenes y el tamaño de nuestro batch.

Finalmente, inicializamos nuestras variables para el optimizador y nuestra función de pérdida. El optimizador utilizado para este caso ha sido Adam, ya que tras numerosas pruebas, el entrenamiento más correcto y eficiente en términos computacionales era este. Lo utilizamos, como podemos ver en el código, con un learning rate de 0.0005. Nuestra función de pérdida sera SparseCategoricalCrossentropy.

Con todas estas variables correctamente definidas, podemos realizar la compilación de nuestro modelo pasándole las variables que acabamos de crear, definir un número de épocas, y llamar a la función .fit(), que se encargará de hacer una iteración de entrenamiento por el número de épocas especificado. En nuestro caso, además, asignamos el valor devuelto por esta función a una variable que nos será útil más adelante en el código para consultar valores y generar gráficos de los resultados obtenidos en el entrenamiento.

Finalmente, utilizamos la función .save() de nuestro modelo para que se genere un archivo en cuyo interior se almacenan los pesos del modelo entrenado, que podremos cargar mas tarde para realizar las predicciones necesarias.

Todos estos términos tienen un fuerte componente matemático detrás, que se extiende al objetivo de este documento, por lo que las explicaciones plasmadas aquí únicamente pretenden clarificar al lector acerca de los términos utilizados y el papel que juegan en el desarrollo del proyecto.

Para más información respecto tanto al contexto matemático como a las diferentes definiciones y

usos de las herramientas mencionadas en esta sección, pueden consultarse las fuentes que figuran en el anexo de información adicional externa:

5.2.5 Validación

Con cada época del entrenamiento, es convención en desarrollo de IA realizar una validación de este, para ver que progresa como es debido y los resultados avanzan en la dirección adecuada, hasta llegar a una validación con la que estemos satisfechos que nos indique que el modelo que hemos entrenado está listo para su uso. En este punto debemos desarrollar una herramienta que compruebe tanto con datos del dataset, como externos a él, que las predicciones que realiza de los datos que le pasamos son acertadas con suficiente certeza y el suficiente número de veces.

Es importante realizar un batch de validación porque entrenar una IA y validar con el mismo set de datos con la que la hemos entrenado no es recomendable; en primer lugar, no sabemos si es capaz de reconocer datos que le sean desconocidos, y en segundo lugar, las métricas que recibamos sobre la precisión y la tasa de acierto se verán afectadas precisamente por haberse entrenado con los mismos datos que intentamos predecir.

La idea detrás de este desarrollo es poder obtener información precisa sobre el rendimiento de nuestra IA, de forma que podamos ajustar sus parámetros en base a ensayo-error (práctica muy común en entrenamiento de IAs) hasta dar con unos ajustes cuyo rendimiento sea satisfactorio. Esto nos permitirá entrenar un número considerable de épocas, hasta que los resultados de la validación muestren un estancamiento del ratio acierto/error.

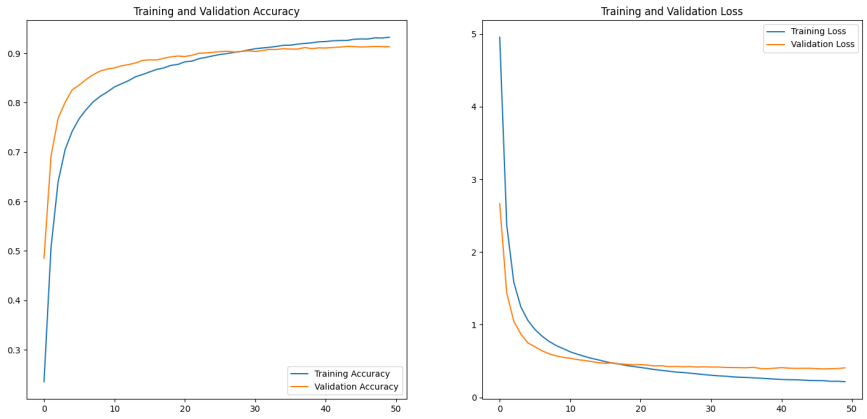

Cabe mencionar que es en este punto donde debemos dejar de entrenar la IA, ya que forzarla a continuar un número excesivo de épocas para conseguir mejoras marginales, puede generar el llamado *overfitting*[7], que causara un mayor número de falsos resultados a la hora de trabajar con datos ajenos al dataset original.

5.3 Implementación

En esencia, debemos encargarnos de que nuestra IA pueda ser utilizada accediendo a ella sin necesidad de ejecutar manualmente un script (como hacemos con nuestra validación), y que los datos que esta genera, puedan ser recibidos e interpretados por otras herramientas en lugar de ser impresos en una consola. Para ello, se distinguen dos puntos fundamentales que desarrollamos a continuación.

Para conocer en detalle el funcionamiento interno, casos de uso de la aplicación, etc. se incluyen varios diagramas UML disponibles en el *Anexo 2.*

[7]Definiciones en Anexo 1: Términos técnicos

5.3.1 Configuración de los métodos

Siguiendo la documentación oficial de la librería que utilicemos, debemos definir los parámetros que la API desea recibir, el protocolo utilizado, la ruta donde desea recibirlos, y demás configuraciones necesarias para después poder consumir esa funcionalidad a través de protocolo HTTP, ya sea utilizando *Postman*[8] o un navegador.

En este caso, tras todo el desarrollo de la IA, se hace una búsqueda sobre las librerías con las que podemos proceder a crear la API. Se decide utilizar las librerías de FastAPI y Uvicorn. La primera librería se encargará de permitirnos crear las funcionalidades que necesitemos para interactuar con nuestro código. La segunda se trata de una implementación para Python de un servidor web ASGI, lo que nos permitirá acceder a él a través de una red.

Una vez configurada la API y levantado el web service con uvicorn, comprobamos que todos estos métodos y la configuración del servicio funcionen correctamente, intentando realizar una request a través de Postman. Una vez consigamos que la respuesta HTTP devuelta sea satisfactoria, aunque no tengamos nuestro resultado, confirmaremos que la configuración de estos puntos es la correcta, y necesitará poca o ninguna configuración extra de aquí en adelante.

5.3.2 Presentación del resultado

Una vez desarrollada correctamente la configuración de la API, faltaría la parte del desarrollo en la que los datos que hemos enviado a nuestro servidor se procesan y recibamos una respuesta en el formato correcto con los datos que ha generado nuestra IA.

Será trabajo de otras herramientas utilizadas cómo procesar la información enviada por nuestra API, sin embargo el formato en el que esta envíe los datos debe ser algo legible y fácilmente procesable, por lo que nuestro resultado se configura para que devuelva un JSON formateado de forma específica para su posterior lectura.

```
  {
    "result": [
      {
      "character": "kanji1",
      "certainty": "0.5"
      },
[...]
      {
      "character": "kanji5",
      "certainty": "0.04"
      }
    ]
  }
```

Formato del JSON de respuesta.

5.4 Alojamiento

Uno de los objetivos de este proyecto es poder consumir la IA a través de un WebService expuesto a internet, por lo que uno de los pasos a seguir será configurar un servidor privado donde alojar la API y exponer sus funcionalidades a internet. Para realizar este punto, debemos seguir los siguientes pasos:

[8] Definiciones en Anexo 1: Términos técnicos

5.4.1 Montaje e instalación del servidor

Se plantea usar como servidor una torre de bajo presupuesto. En este ordenador se instalará la versión estable mas reciente de *Linux Debian*[9], sin ningún tipo de interfaz gráfica ni utilidades extras a las propias del Sistema Operativo a parte de Docker, para la creación de *containers*[9]; Git, para descarga y manejo de repositorios; y NeoVim, un editor de texto de terminal para gestionar los archivos de configuración necesarios en el servidor

La instalación y configuración inicial se realiza de la forma habitual, y una vez configurada la red y el acceso por *SSH*[9], desconectamos todos los periféricos y utilizamos una conexión SSH para acceder a él sin necesidad de compartir o utilizar periféricos extra, conectándonos desde el mismo sistema desde el que realizamos nuestro desarrollo.

Esto es particularmente útil ya que quitamos del servidor cualquier tipo de software que pueda consumir sus recursos de forma innecesaria. En su lugar, trabajamos con el mismo equipo con el que desarrollamos y configuramos todas las características propias del código fuente, y a través de una consola de comandos, modificamos y configuramos aquello que necesitemos en nuestro servidor de forma remota.

5.4.2 Networking

Para que el sistema que instalamos en el punto anterior pueda realizar las funciones de servidor que necesitamos, tenemos que realizar diversos ajustes de *networking*[9] que explicamos a continuación.

En primer lugar, debemos asegurarnos una *IP pública*[9]. Para esto, se contacta con nuestro *ISP*[9], y se le solicita que se nos asigne una *IP dinámica*[9] fuera del *CGNAT*[9].

Hecho esto, le asignamos a nuestro servidor una *IP estática*[9] dentro de nuestra red local, y la asignamos a un *dominio*[9] de tal forma que las conexiones del exterior siempre accedan a través de la misma dirección.

Legalmente, nuestro ISP tiene la obligación de proveernos una IP pública, sacándonos del CGNAT en el que nos tengan. Por suerte, O2 (Telefónica) únicamente asigna IPs públicas a sus clientes, por lo que durante este desarrollo no se ha necesitado llevar a cabo este trámite.

Técnicamente, también tienen la obligación de proveernos una IP estática, sin embargo, al contrario que una IP dinámica como mencionamos anteriormente, esto no se contempla de forma gratuita, sino que se trata de un servicio de pago.

Dado que para este proyecto ya disponemos de una IP pública, nos es suficiente para poder configurar el servidor acorde a nuestras necesidades. En primer lugar, se compra un dominio a través de Namecheap.com (otterleek.com). A continuación, nos registramos en NoIP.com, un servicio gratuito que se encarga de monitorizar nuestra IP y asignarle de forma dinámica un *DNS*[9] desde el que poder conectarte.

En términos generales, la IP pública que nos proporciona nuestro ISP se mantiene hasta que nuestro router se reinicia o pierde su conexión. Si en algún momento el ISP cambia nuestra IP, NoIP.com lo detecta, y apunta el dominio que hemos solicitado a nuestra nueva IP. NoIP ofrece este servicio de forma gratuita con la condición de confirmar una vez al mes que continuamos utilizando sus servicios.

Solucionado el problema de que podamos acceder a nuestra IP en cualquier momento que queramos independientemente de si ha cambiado o no, quedaría reasignar nuestro dominio al que hemos adquirido. Para ello la propia página de Namecheap tiene unas opciones de configuración DNS con las que podremos realizar estos cambios. Para nuestra IA crearemos un subdominio al que podremos enviar una petición HTTP (kanji.otterleek.com) que apuntaremos al DNS facilitado por NoIP.

Con esta configuración ya tendríamos el networking listo para poder configurar un container a través del que podremos hacer consultas sobre nuestro web service.

[9]Definiciones en Anexo 1: Términos técnicos

5.4.3 Dockerización

Por último, dentro de nuestro servidor, para que pueda convivir con más aplicaciones y herramientas, instalaremos nuestra API en un container de Docker y le asignaremos el puerto que deseemos, asegurándonos de que todo está correctamente expuesto a internet y que el container es capaz de mantenerse activo sin mantenimientos adicionales.
El proceso para esto es bastante simple. En nuestro directorio root del servidor, introducimos los comandos

```
mkdir -p Docker/Kanji-AI && cd $_
nvim Dockerfile
```

Esto creará un directorio donde almacenaremos toda la configuración de nuestro container y un archivo Dockerfile donde definiremos los parámetros de instalación e inicialización del container:

```
FROM python:3.8
WORKDIR /code
COPY ./requirements.txt /code/requirements.txt
RUN pip install --no-cache-dir --upgrade -r /code/requirements.txt
COPY ./app /code/app
CMD ["uvicorn", "app.main:app", "--proxy-headers", "--host", "0.0.0.0", "--port", "39000"]
```

Para que el proyecto funcione correctamente deberá instalar una serie de librerías que le pasamos en un archivo de texto llamado *requirements.txt* como puede verse en el fichero anterior, que debemos crear con el siguiente contenido:

```
fastapi>=0.68.0
pydantic>=1.8.0
uvicorn>=0.15.0
numpy
tensorflow
pillow
python-multipart
matplotlib
```

Este proceso creará una instalación del container con las dependencias necesarias, sin embargo, necesitamos configurarlo correctamente para que al levantarse, se conecte correctamente con los puertos indicados, en la network adecuada, y a través del protocolo HTTPS.

Para esto debemos crear un *docker-compose.yml*, aunque antes debemos realizar una correcta instalación y configuración de Traefik, un *reverse-proxy*[10] y *load-balancer*[10] integrado nativamente con Docker para permitirnos exponer a internet servicios desde nuestros containers. Como la configuración de Traefik es compleja y extensa, y va más allá del objetivo de esta documentación, estará disponible una breve explicación en el *Anexo 3* sobre configuración de Traefik.

Una vez realicemos la correcta instalación y configuración de Traefik, podremos crear el fichero mencionado anteriormente con el siguiente contenido:

[10] Definiciones en Anexo 1: Términos técnicos

```
name: kanjiAI
services:
  kanjiAI:
      build: .
      image: kanji-AI
      container_name: kanji-AI
      working_dir: /code/app
      command: "uvicorn main:app --host 0.0.0.0 --port 39000 --reload"
      ports:
          - "39000:39000"
      volumes:
          - .app:/code/app
      restart: "unless-stopped"
      networks:
          - traefik-global-proxy
      labels:
          - "traefik.enable=true"
          - "traefik.http.routers.ai.rule=Host(‘kanji.otterleek.com‘)"
          - "traefik.http.routers.ai.tls.certresolver=letsencrypt"
          - "traefik.http.routers.ai.entrypoints=https"
          - "traefik.http.services.ai-service.loadbalancer.server.port=39000"
networks:
  traefik-global-proxy:
      external: true
```

Tras realizar esta configuración, debemos abrir el puerto 39000 TPC en nuestro router. Podemos hacer esto accediendo a él a través de nuestra puerta de enlace y utilizando el software que los propios router implementan.

Por último, debemos incluir nuestro desarrollo en una carpeta llamada *app/* (como puede verse en los archivos de configuración) dentro de nuestra carpeta de configuraciones del container, y levantar el container en modo detached para que el proceso del container no inutilice nuestra consola.

```
docker compose up -d
```

Nuestra IA estaría en este punto lista para utilizarse a través de internet, y podemos comprobar su correcto funcionamiento haciendo una petición HTTP *multipart*[11] al dominio mencionado anteriormente (https://kanji.otterleek.com) con una imagen adjunta. La imagen llegará entonces a nuestro WebService y nuestro desarrollo realizará una predicción de los cinco kanjis más posibles en esa imagen, devolviéndonos una respuesta HTTP en el formato JSON mencionado previamente en esta misma sección.

5.5 Creación de la interfaz

Respecto a la creación de la interfaz, simplemente distinguiremos dos desarrollos, el diseño de la interfaz incluyendo sus funcionalidades, disposición y la interacción entre sus ventanas por un lado, y el desarrollo para contactar con el web service y procesar sus respuestas por otro.

5.5.1 Frontend

La intención original es que la app sea extremadamente simple, disponiendo de dos funcionalidades básicas, capturar una imagen (únicamente para dispositivos con cámara), y cargar una imagen desde la memoria del dispositivo.

Una vez cargada, mostrará la imagen a enviar para asegurarnos de que se ve correctamente y el caracter está correctamente acotado en la imagen para solicitar su predicción, junto con dos botones, uno para eliminar la imagen seleccionada y repetir el proceso, y otro para contactar con el web service, que una

[11] Definiciones en Anexo 1: Términos técnicos

vez pulsada, esperará la respuesta de éste, y nos llevará a una ventana donde se muestre la predicción junto con el botón de salida.

Para todo este desarrollo hemos utilizado Flutter, un framework basado en el lenguaje Dart enfocado en el desarrollo de aplicaciones multiplataforma que permite reutilizar nuestro código con las modificaciones mínimas para crear versiones para los dispositivos más utilizados hoy en día.

El desarrollo de la interfaz es una simple estructura de componentes, por lo que no considero necesario entrar en detalle sobre el código como tal, que estará disponible en el repositorio. Para cualquier información relativa a esta parte del desarrollo, puede consultarse la documentación oficial de Flutter.

5.5.2 Back end

Respecto a la funcionalidad que se desarrolle por debajo de la interfaz, nos centraremos casi de forma exclusiva en poder enviar la imagen al web service correctamente, y ser capaces de recibir y procesar su respuesta para mostrarla por pantalla.

Hay diversas utilidades para hacer que el dispositivo cargue una imagen de la galería o acceda a la cámara para capturar una imagen, por lo que no nos vamos a detener en la explicación de esto, sin embargo, la parte compleja de este desarrollo consiste en realizar satisfactoriamente una petición HTTP multipart que nos permita enviar la imagen a nuestro WebService, y recibir y formatear su respuesta correctamente.

Esta parte del desarrollo se sustenta sobre dos fragmentos de código que explico a continuación.

Flutter implementa nativamente el envío de peticiones HTTP multipart, por lo que hemos utilizado la siguiente función para solicitar una predicción a nuestra IA:

```
Future<Prediction> requestPredictionAPI(File kanji, BuildContext context) async{
  final request = http.MultipartRequest('POST', Uri.parse('https://kanji.otterleek.com/'));
  request.files.add(await http.MultipartFile.fromPath('file', path!));
  final response = await request.send();
  if (response.statusCode==200){
      String b = (await http.Response.fromStream(response)).body;
      return Prediction.fromJson(jsonDecode(b));
  }
  else{
      Navigator.of(context).push(MaterialPageRoute(builder: (context) => Unavailable()));
      throw Exception('Kanji AI Predict WebService is unavailable');
  }
}
```

Donde Prediction es una clase que recoge la respuesta HTTP y la transforma en consecuencia para poder acceder a los datos de respuesta desde el código más adelante:

```dart
class Prediction{
  final List<Content> content;
  Prediction({
      required this.content,
  });
  factory Prediction.fromJson(Map<String, dynamic> json) => Prediction(
      content: List<Content>.from(json['result'].map((x) => Content.fromJson(x))));
  Map<String, dynamic> toJson() => {
      "result": List<dynamic>.from(content.map((e) => e.toJson()))
  };
}

class Content {
  final String character;
  final double certainty;
  Content({
      required this.character,
      required this.certainty
  });
  factory Content.fromJson(Map<String, dynamic> json) => Content(character: json['character'
    ], certainty: json['confidence']);

  Map<String, dynamic> toJson() => {
      "character": character,
      "certainty": certainty
  };
}
```

6 Puntos a mejorar

Aunque la realización de este proyecto es satisfactoria, debido a la falta de tiempo, capacidades, u otras variables, algunos aspectos de este proyecto tienen una amplia capacidad de mejora. En este punto trataremos brevemente futuras mejoras a desarrollar para nuevas versiones. Mencionar antes de nada, que el objetivo de este apartado no es presentar aspectos con los que ampliar la funcionalidad de la aplicación, sino para elaborar puntos de mejora en el rendimiento, la facilidad de uso, etc. considerables que no se han podido aplicar por diversas circunstancias.

- **Utilizar *data augmentation***[12]: El uso de data augmentation puede mejorar mucho la capacidad predictiva de la IA en casi cualquier escenario, sin embargo, no se ha implementado porque para esto se requiere de un poder computacional y un tiempo de entrenamiento muy elevado.
- **Implementar distinción de kanjis**: Se podría implementar un algoritmo capaz de analizar la imagen e identificar kanji que pueda haber en ella, y generar un encuadre correcto en torno a la figura para el posterior análisis por parte de nuestra IA. Esto haría que la experiencia de usuario y los casos de uso mejorasen sustancialmente, sin embargo no se ha considerado su implementación tanto por el factor de tiempo como por el de dificultad.
- **Mejorar el procesado de imágenes**: La IA es propensa a fallos cuando las fotografías se realizan en escenarios de poca luz debido al poco rango dinámico de los dispositivos, la cantidad de ruido, y el poco contraste presente en las imágenes tomadas en estas circunstancias. Un procesamiento de la imagen más exhaustivo, que analice la cantidad de luz, el contraste de la escena, y sea capaz de proveer un kanji en el mayor número de condiciones desfavorables posibles es un aspecto importante a tener en cuenta.
- **Interfaz más profesional**: El mayor peso de este proyecto recae sobre todo el proceso de creación de la IA y la comunicación con ella, por lo que la interfaz de usuario es excesivamente simple y con muy pocas funcionalidades. Es necesario considerar cambiar este diseño para sus futuras versiones y a ser posible añadir alguna funcionalidad extra para la comodidad del propio usuario.
- **Crear un instalador**: Se contempla como uno de los futuros desarrollos, una forma de crear un instalador de esta IA de forma que se aloje localmente en un dispositivo y podamos acceder a ella a través de una conexión local sin necesidad de acceder a internet. También facilitará todo el proceso de entrenamiento, que actualmente se lleva a cabo lanzando los scripts manualmente en el orden indicado en el archivo README. Este documento está disponible en la página principal del repositorio y en el *Anexo 3.*

[12]Definiciones en Anexo 1: Términos técnicos

7 Recursos

El detalle de todos los recursos utilizados en este proyecto consiste en:

7.1 Recursos humanos

Los recursos humanos son virtualmente inexistentes. El proyecto se desarrolla de forma unipersonal, gestionando mi tiempo y mis recursos para la conclusión de los objetivos marcados en éste.

Únicamente cabe destacar la ayuda puntual de compañeros de clase, de profesión, y personal docente del centro que se verá reflejada en el anexo de agradecimientos.

7.2 Hardware

- Un smartphone donde realizar pruebas de la aplicación móvil
- Un ordenador donde se desarrollará el proyecto junto con sus periféricos compuesto por:
  - CPU AMD Ryzen5 5600
  - GPU AMD Radeon 6600
  - RAM Viper 32Gb DDR4
  - SSD M.2 500Gb Crucial
  - Otros componentes (PSU, Fuente de Alimentación, Caja...)
  - Teclado Logitech MX Keys
  - Raton Logitech MX Master M3s
  - Monitores AOC 24G2U (x2)
- Un servidor compuesto por:
  - CPU Intel i3 2120
  - RAM Kingston 6Gb DDR
  - SSD SATA3 Kingston 160Gb
  - Otros componentes (PSU, Fuente de Alimentación, Caja...)
- Diversos cables de conexión, corriente, etc. (Ethernet, HDMI, DP, USB-C...)

7.3 Software y Servicios

- Un dominio ("otterleek.com")
- Una conexión a Internet (O2)
- Licencias:
  - PyCharm Community Edition
  - Debian 12.2
  - Docker
  - Visual Studio Code
  - Postman
  - Overleaf
- Diversas librerías de terceros (Tensorflow, Keras, Pillow...) que han sido mencionadas a lo largo del proyecto

7.4 Presupuesto

El total del presupuesto incluye los 5 meses de desarrollo de la aplicación, y un solo año de dominio, sin embargo con futuros desarrollos, debido al pago de estos servicios, puede verse incrementado.

Algunos componentes son piezas genéricas de fabricantes que no están disponibles al público para su compra, por lo que ha sido todo agrupado bajo un mismo nombre genérico, y su precio se ha calculado en base a precios de componentes de características similares, al igual que con los cables utilizados, muchos proveídos por los propios fabricantes de los componentes. Estos elementos son: caja, placa base y fuente de alimentación del servidor, pilas CMOS, pasta térmica, cables SATA, cables HDMI, cables DisplayPort, cables USB y USB-C y cables de alimentación.

Detalle	Cantidad	Precio
Asus Prime b550-Plus	x1 ud.	109.99€
AMD Ryzen5 5600	x1 ud.	137.52€
Intel i3 2120	x1 ud.	32.46€
Xilence XC032	x1 ud.	16.01€
XFX Speedster SWFT 210	x1 ud.	229.90€
Viper 16Gb DDR4 3600mHz	x2 ud.	36.59€
Kingston 4Gb DDR3 1333mHz	x1 ud.	22.14€
Kingston 2Gb DDR3 1333mHz	x1 ud.	17.24€
M.2 Crucial 500Gb	x1 ud.	40.99€
SATA3 Kingston 160Gb	x1 ud.	21.80€
SeaSonic Core GM 500W	x1 ud.	86.99€
Lian Li Mesh 205	x1 ud.	61.72€
AOC 24G2U	x2 ud.	255.10€
Logitech MX Keys	x1 ud.	89.99€
Logitech MX Master M3	x1 ud.	91.41€
Xiaomi Redmi Note 12 Pro 5G	x1 ud.	289.99€
Otros componentes*	sin especificar	97.39€
Diversos cables*	sin especificar	34.02€
Dominio "otterleek.com"	pago anual (x1)	9.76€
Conexión a internet	pago mensual (x5)	38.00€
TOTAL		**2002.11€**

8 Anexos

8.1 Términos técnicos

- **Kanji:** Son sinogramas utilizados en la escritura del idioma japonés, junto con los silabarios *hiragana y katakana*. Se usan mayoritariamente para expresar conceptos, a diferencia de su variante china, donde se emplean también con caracter fonético. Asimismo, existen combinaciones de kanji que no obedecen a su significado original y modifican el valor fonético asignado de sus componentes. A cada kanji le corresponde un significado y se usa como determinante la raíz de la palabra, y sus derivaciones o conjugaciones se expresan mediante el hiragana. Un kanji puede tener diferentes pronunciaciones o 'lecturas' dependiendo de su contexto, uso y localización, pero es muy poco común que un kanji tenga varios significados que disten mucho entre ellos.

- **Modelo:** Consiste en un formato de datos en el que se especifican las instrucciones de procesamiento de datos para permitir que el sistema que éste define sea capaz de aprender patrones específicos presentes en los conjuntos de datos que tenemos como objetivo, y formular predicciones a partir de ellos.

- **Data science:** Se trata de una disciplina científica centrada en el análisis de grandes fuentes de datos para extraer información, comprender su significado y descubrir patrones dentro de ellas. En ella se combinan matemáticas, estadística e informática, generalmente con el objetivo de optimizar la toma de decisiones respecto a un problema concreto.

- **Unicode:** Es un estándar de codificación de caracteres diseñado para facilitar el tratamiento informático, transmisión y visualización de textos de numerosos idiomas y disciplinas. Se define cada caracter mediante un nombre e identificador numérico y todos se tratan de forma equivalente para poder ser utilizados en un texto sin necesidad de utilizar marcas o caracteres de control. A día de hoy, el sistema puede representar 149.186 caracteres, incluyendo entre ellos caracteres de formato como saltos de línea o tildes, de un espacio posible de 1.114.112(0x10FFFF) menos los caracteres reservados para el uso interno del sistema.

- **IA:** De Inteligencia Artificial. Es un campo de la ciencia relacionado con la creación de sistemas que sean capaces de razonar, aprender y actuar simulando la inteligencia humana o involucrando cantidades de datos más allá de la capacidad de análisis humana. Es un campo que en sí mismo abarca muchas disciplinas, como la informática, el análisis de datos, la estadística, el procesamiento del lenguaje natural, la neurociencia, entre otras. A nivel práctico, se trata de una tecnología basada en el aprendizaje automático, que analiza datos y genera las respuestas requeridas frente a un problema.

- **API:** Del inglés, Application Programming Interface, son un código o conjunto de estos que permiten a diferentes aplicaciones comunicarse entre sí y compartir información y funcionalidades a modo de intermediario entre ambos sistemas.

- **Web service:** Es una forma estandarizada de establecer una comunicación y/o realizar intercambios de datos entre diferentes aplicaciones a través de internet mediante los protocolos comúnmente utilizados en tecnologías web.

- **Clasificador KNN:** Del inglés, K-Nearest-Neighbors, es un método de clasificación que busca en las observaciones más cercanas al dato de entrada, y lo clasifica basándose en la mayoría de datos que le rodean. Se trata de un algoritmo supervisado y basado en instancia, es decir, que nuestros datos están etiquetados con una clase o resultado, y el algoritmo predice en base a estos (supervisado) y que el algoritmo no realiza un aprendizaje como tal, sino que carga las instancias en memoria para realizar la predicción en base a estas.

- **Red neuronal:** En términos simples, es un método de IA que se encarga de procesar datos de una manera inspirada en el funcionamiento de las neuronas del cerebro humano. Es un proceso que utiliza

nodos interconectados en una estructura de capas capaz de producir un sistema adaptable que aprende en base a los errores producidos en sus procesos anteriores.

- **Validación:** Se trata de un proceso por el cual analizamos la validez del modelo generado en base a la precisión de sus predicciones. Para ello se utiliza un conjunto de validación, que a diferencia de nuestro conjunto de datos principal, no se utiliza para ajustar los parámetros del modelo, sino para evaluar su rendimiento final, y que no está autocontenido en el conjunto de entrenamiento para producir resultados fiables.
- **OCR:** Del inglés Optical Character Recognition, es un método de reconocimiento de caracteres que es capaz de identificar y extraer textos a partir de una imagen.
- **Overfitting:** Es un efecto común en el entrenamiento de IAs en el que nuestro modelo solo se ajusta a aprender los casos concretos que le estamos proporcionando durante el entrenamiento, y su rendimiento al reconocer nuevos datos de entrada se ve deteriorado.
- **Postman:** Se trata de un cliente HTTP para producir, probar y utilizar APIs tipo REST a través de peticiones HTTP con una interfaz gráfica de usuario.
- **ASGI:** Del inglés Asynchronous Server Gateway Interface, es una interfaz estándar de comunicación entre servidores web y aplicaciones web para manejar llamadas tanto síncronas como asíncronas a través de frameworks y aplicaciones de Python.
- **Linux Debian:** Se trata de una distribución de GNU/Linux de código abierto, no comercial y totalmente gratuito para todos sus usos. Es una de las distribuciones más importantes y populares hoy en día en lo que respecta a la administración de servidores por su alta estabilidad.
- **SSH:** Del inglés Secure Shell, es un protocolo de administración remota tipo cliente-servidor a través del cual los usuarios pueden tanto modificar como controlar servidores remotos a través de una red bajo una capa de encriptación.
- **Networking:** Se refiere a la creación, configuración y mantenimiento de redes a través de las cuales múltiples dispositivos y sistemas se comunican entre ellas y comparten información.
- **ISP:** Del inglés Internet Service Provider, hace referencia a la empresa encargada de proveer y gestionar nuestra conexión a internet.
- **IP:** Del inglés Internet Protocol, es una etiqueta numérica que identifica de manera lógica y jerárquica a una interfaz (generalmente un dispositivo físico) conectada a la red que utilice el protocolo de internet TCP/IP. Una IP pública es por tanto, una dirección IP asignada por nuestro ISP a través de la cual nos identificamos en internet al conectarnos. Una IP dinámica se refiere al hecho de que, debido a la forma de trabajar de los ISP y el número limitado de direcciones, la dirección IP puede verse afectada y cambiar en el tiempo (normalmente al reiniciar el router). Dentro de nuestra dirección de IP pública, existen un cierto número de direcciones utilizables que llamaremos IPs internas. Estas direcciones suelen asignarse a distintos dispositivos de forma dinámica cuando acceden a una red local, sin embargo en la mayoría de los casos, podemos forzar a nuestros dispositivos a que se les asigne una IP interna concreta o estática, para asegurarnos que siempre trabajan bajo la misma dirección.
- **CGNAT:** Se trata de una solución que utilizan algunos operadores para poder conectar varios equipos a internet bajo una misma dirección IP pública, a la que se asocian distintas direcciones IP privadas, por lo que todas éstas, pasan a ser identificadas bajo la misma dirección. Es por esto, que cuando un dispositivo fuera de la CGNAT intenta acceder a un dispositivo dentro de ella, en realidad está intentando acceder a una dirección que contiene múltiples destinos, y por tanto, hace inviable exponer direcciones a internet de forma pública.

- **Dominio:** Se trata de un nombre exclusivo que se le da a un sitio web para identificarlo y facilitar su acceso para los usuarios.
- **Container:** Son una forma de virtualización de sistemas operativos que contienen los ejecutables, librerías, y archivos de configuración necesarios para ejecutar algún tipo de servicio. Al contrario que con las máquinas virtuales, los containers no virtualizan abstrayendo el hardware de la máquina, sino que abstraen el sistema operativo al nivel más bajo posible para que nuestro servicio o aplicación pueda ejecutarse, por lo que son mucho más ligeros y eficientes. La herramienta más extendida para la gestión de containers a día de hoy es Docker.
- **Reverse proxy:** Se trata de un servidor que se sitúa delante de los servidores web, en una capa situada entre internet y el lado servidor y reenvía las solicitudes por parte del lado del cliente a dichos servidores. Suelen implementarse para aumentar la seguridad y el rendimiento de estos servicios.
- **Load balancer:** Se trata de una tecnología orientada a la optimización de cargas de trabajo para que un grupo de servidores pueda hacer frente de forma eficiente a picos de tráfico, equilibrando la carga entre los distintos servidores para mantener su capacidad a un nivel óptimo, de modo que sean menos propensos a interrupciones o ralentizaciones.

8.2 Esquemas

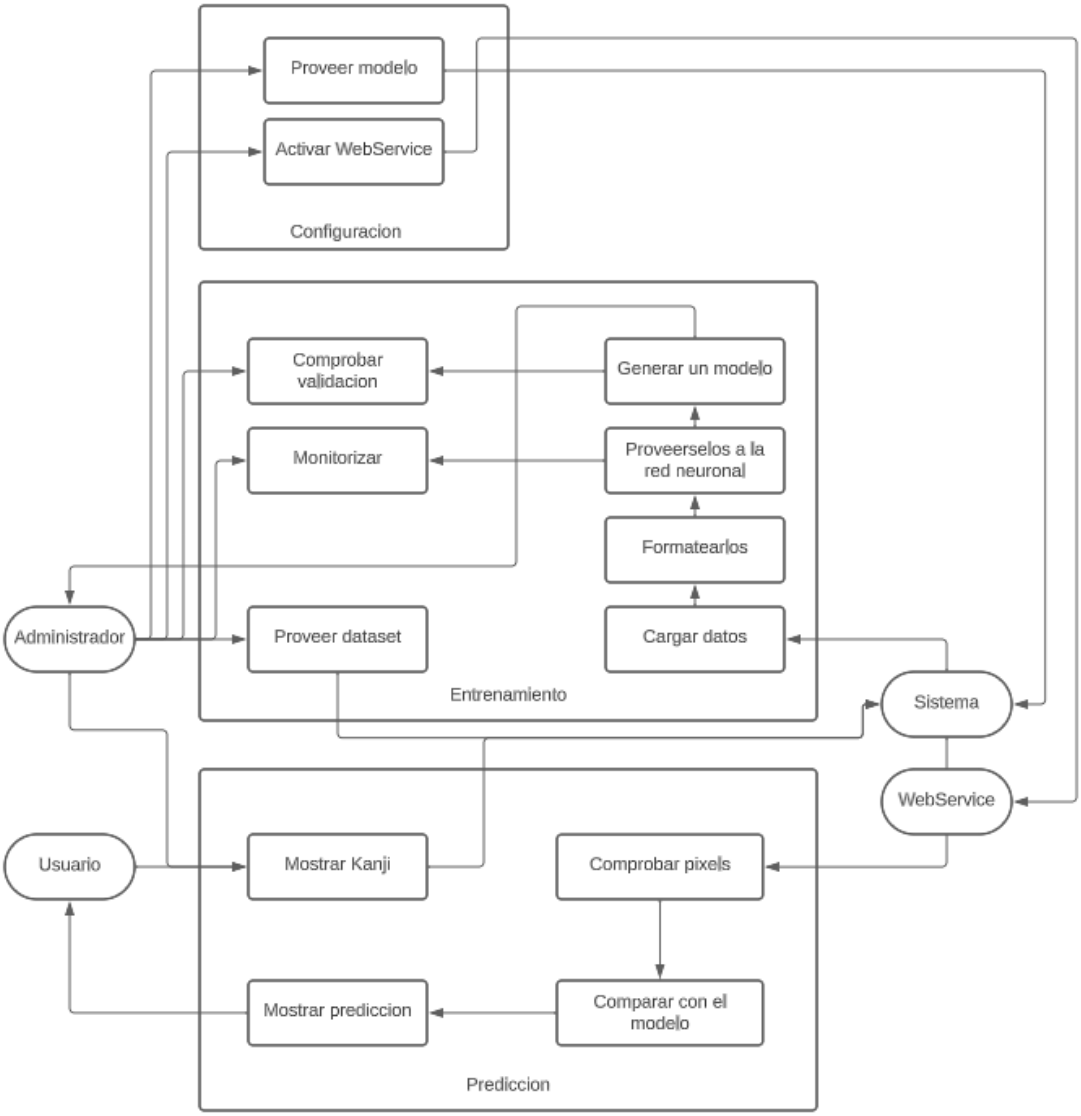
Proveer modelo
Activar WebService
Configuracion
Comprobar validacion
Generar un modelo
Monitorizar
Proveerselos a la red neuronal
Formatearlos
Administrador
Proveer dataset
Cargar datos
Entrenamiento
Sistema
WebService
Usuario
Mostrar Kanji
Comprobar pixels
Mostrar prediccion
Comparar con el modelo
Prediccion

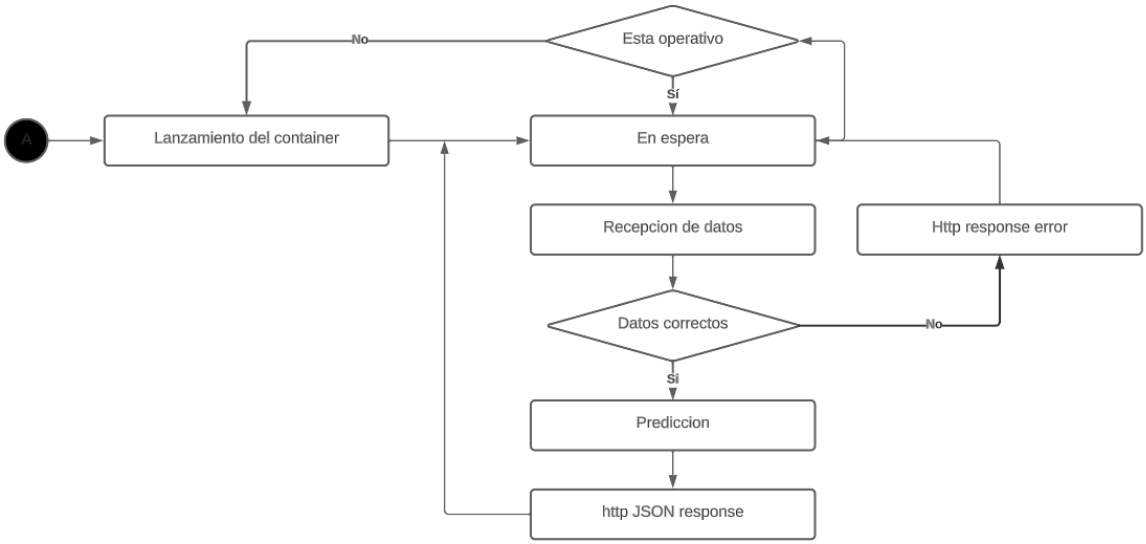
Esta operativo
No
Sí
A
Lanzamiento del container
En espera
Recepcion de datos
Http response error
Datos correctos
No
Sí
Prediccion
http JSON response

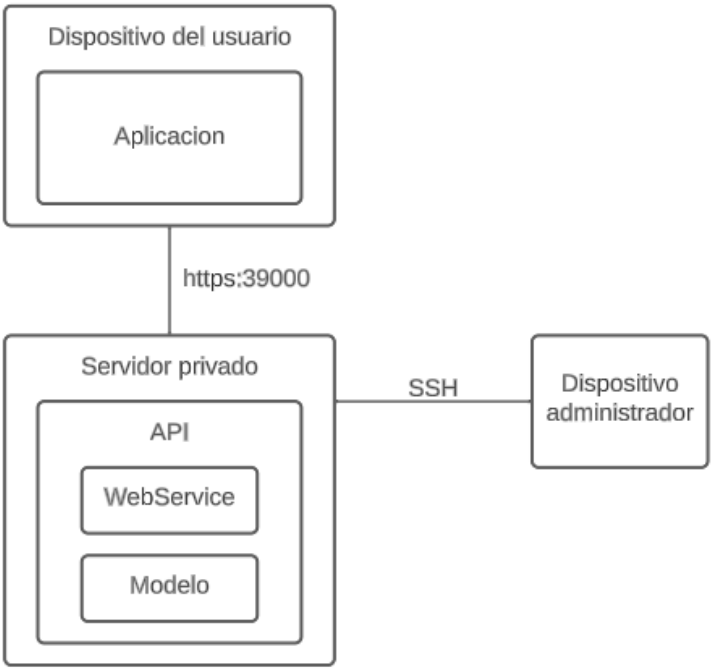
Dispositivo del usuario
Aplicacion
https:39000
Servidor privado
API
WebService
Modelo
SSH
Dispositivo
administrador

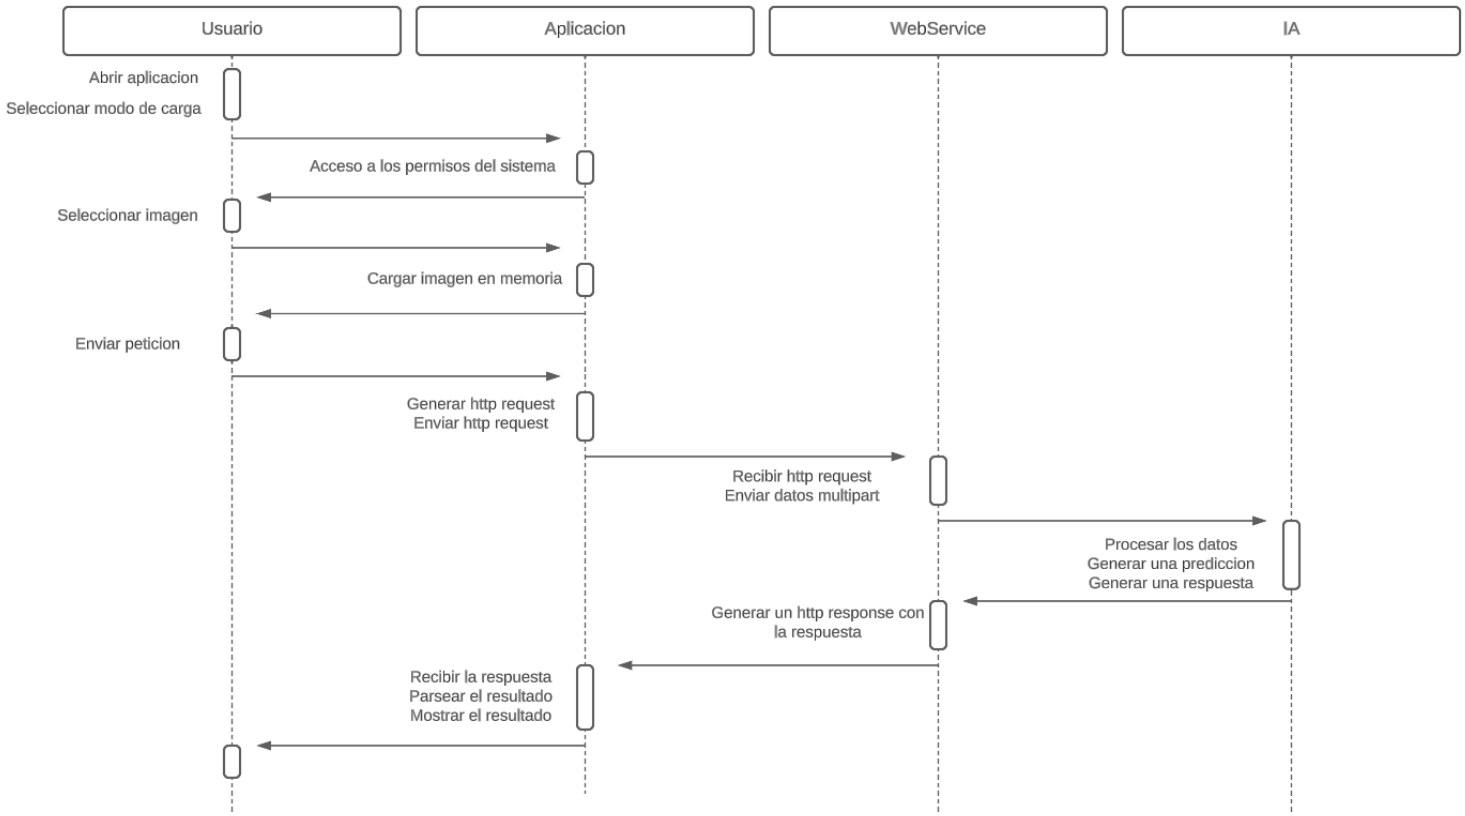
Usuario
Aplicacion
WebService
IA
Abrir aplicacion
Seleccionar modo de carga
Acceso a los permisos del sistema
Seleccionar imagen
Cargar imagen en memoria
Enviar peticion
Generar http request
Enviar http request
Recibir http request
Enviar datos multipart
Procesar los datos
Generar una prediccion
Generar una respuesta
Generar un http response con
la respuesta
Recibir la respuesta
Parsear el resultado
Mostrar el resultado

8.3 Guía del desarrollador

8.3.1 Configuración de Traefik

Como se ha explicado previamente, para poder exponer nuestra aplicación a internet a través de nuestro servidor dockerizado, debemos configurar correctamente Traefik.

Sin entrar en demasiados tecnicismos, en este punto desarrollaremos cómo crear una configuración básica de Traefik con la que trabajar. Para más información, Traefik dispone de una amplia documentación online en la que solventar posibles dudas de funcionamiento y configuración.

En primer lugar, debemos crear una carpeta para el container de docker dentro de nuestro servidor, que almacenará el servicio Traefik y su configuración. En esta carpeta, crearemos un archivo *docker-compose.yml* con la siguiente configuración:

```
version: "3.7"
services:
  traefik:
      image: traefik:2.4.8
      container_name: traefik
      networks:
          - traefik-global-proxy
      command:
          - --entrypoints.http.address=:80
          - --entrypoints.https.address=:443
          - --providers.docker=true
          - --providers.docker.network=traefik-global-proxy
          - --providers.docker.exposedByDefault=false
          - --api=true
          - --certificateresolvers.letsencrypt.acme.httpchallenge=true
          - --certificateresolvers.letsencrypt.acme.httpchallenge.entrypoint=http
          - --certificateresolvers.letsencrypt.acme.email=#<email>
          - --certificateresolvers.letsencrypt.acme.storage=/letsencrypt/acme.json
      labels:
          - traefik.enable=true
          - traefik.http.routers.to-https.rule=HostRegexp(‘{host:.+}‘)
          - traefik.http.routers.to-https.entrypoints=http
          - traefik.http.routers.to-https.middlewares=to-https
          - traefik.http.routers.traefik.rule=Host(‘traefik.otterleek.com‘)
          - traefik.http.routers.traefik.entrypoints=https
          - traefik.http.routers.traefik.middlewares=auth
          - traefik.http.routers.traefik.service=api@internal
          - traefik.http.routers.traefik.tls=true
          - traefik.http.routers.traefik.tls.certresolver=letsencrypt
          - traefik.https.middlewares.to-https.redirectscheme.scheme=https
          - traefik.https.middlewares.auth.basicauth.users=leek:#<KEY>
      ports:
          -80:80
          -443:443
      volumes:
          - ./data/letsencrypt: /letsencrypt
          - var/run/docker.sock:/var/run/docker.sock:ro
networks:
  traefik-global-proxy:
      name: "traefik-global-proxy"
```

Con esta configuración, y completando los puntos marcados con #<...> con los parámetros correspondientes, se procede a levantar el container, y a través del docker compose y la configuración ya mencionados en esta guía con la que levantamos nuestro web service, la ruta especificada en este último ya entraría a través del dominio y los puertos especificados y, además, a través del protocolo https gracias a Let's Encrypt, una autoridad de certificación gratuita y para uso público.

De nuevo, como no es el propósito de este documento elaborar procesos de configuración detallados

respecto a las herramientas externas utilizadas en el proyecto, cualquier información adicional puede obtenerse en la documentación oficial de Traefik.

8.3.2 .README

```
## Documentation

[Docker](https://linktodocumentation)
[Traefik](https://linktodocumentation)
[FastAPI](https://linktodocumentation)
[Python](https://linktodocumentation)
[Debian](https://linktodocumentation)
[Flutter](https://linktodocumentation)
[Tensorflow](https://linktodocumentation)

## Requirements

### For running:
 - Docker or Python 3.8 installed on your machine

### For training:
 - Python 3.8
 - 32Gb RAM as it is, adaptable to run on 16Gb
 - 2Gb of storage available
 - Recommended Ryzen 5 5600 or higher
 * Note: Having a physical GPU available will decrease significantly the training times. It
    is recommended to have CUDA, although we include a package in requirements.txt that
    allows a translation from AMD Technology to CUDA (only for Windows OS)

## Run locally

To train the IA locally:

 - Clone the project
 - Install dependencies provided in ‘requirements.txt‘
 - Download the dataset and the necessary fonts provided in the "necessary files" section
 - Unzip them in the root of the folder with the same name
 - Run the training_process.py script and wait for it to end


To run the IA locally without a container:

 - Clone the project
 - Install dependencies provided in ‘requirements.txt‘
 - Run the main with uvicorn.


To deploy the IA locally end expose it to global network:

 - Follow the instructions provided in the section "Networking" of the documentation
 - Open the correct port
 - Clone the project
 - Create a container with the Dockerfile provided in the repository and the documentation
 - Run the container

 ## API Reference

#### Get a prediction

‘‘‘https
```

```
  POST kanji.otterleek.ddns/
```

Parameter	Type	Description
`file`	`multipart`	**Required**. Kanji image.

8.4 Agradecimientos

Por último, quiero dedicar este pequeño fragmento a agradecer a toda la gente que ha hecho este proyecto posible. En primer lugar, a Jordi Amoros por sugerirme la idea, introducirme en el campo de la inteligencia artificial, y ayudarme con la revisión tanto del proyecto, como de esta documentación. En segundo lugar, a Vadim 'Ame' Perepelitsyn por guiarme en el proceso de networking y creación de containers, y finalmente a Javier Villegas por su ayuda en todo lo referente a estructuras de datos en python. Este proyecto hubiese sido prácticamente imposible sin vuestro apoyo.

Un agradecimiento también a todo mi entorno, profesorado, familia y amigos, que me han ayudado y apoyado durante el curso y el desarrollo del proyecto.

Gracias a todos.

9 Bibliografía